

Facultad de Ingeniería
Tecnologías de la información y optimización de procesos
Preprocesamiento de datos
2026-1

Proyecto final – Integración de todo lo aprendido en clase y más!

Contexto:

En el mundo real, los datos nunca llegan limpios. Las encuestas de bienestar organizacional son uno de los instrumentos más comunes en el ámbito del talento humano, pero también uno de los más propensos a generar datos con problemas de calidad: respuestas inconsistentes, errores tipográficos al digitar, valores imposibles, duplicados por doble envío de formulario, formatos mezclados y códigos de ausencia heterogéneos que dificultan el análisis posterior.

Una consultora recolectó datos sobre indicadores de bienestar y salud mental aplicando una encuesta a 412 trabajadores de diferentes sectores y cargos en Colombia. El archivo fue exportado directamente del sistema de recolección sin ningún proceso de validación previo. El equipo de análisis que iba a procesar los datos reportó que el dataset no es apto para análisis en su estado actual: contiene múltiples tipos de errores que deben ser identificados, documentados y corregidos antes de que cualquier análisis tenga validez.

Su equipo ha sido contratado para construir un **pipeline de preprocesamiento robusto, documentado y reproducible** que entregue como producto final un dataset limpio, estandarizado y listo para ser consumido por el equipo de análisis. El trabajo no termina en limpiar los datos: deben demostrar que entienden por qué cada decisión de limpieza fue tomada, qué impacto tiene sobre los datos y cómo verificar que el resultado es correcto.

DATASET ASIGNADO

Archivo: bienestar_laboral_preprocesamiento.xlsx

Dimensiones: 412 registros × 112 variables

Estructura:

- 21 variables sociodemográficas y laborales (Edad, Sexo, Cargo, Sector, Modalidad, etc.)
- 91 ítems de escala organizados en 16 dimensiones psicosociales
- Escalas de respuesta en texto categórico ordinal y numérica 1-7

IMPORTANTE: Este archivo contiene problemas deliberados de calidad de datos. Su tarea es encontrarlos todos, documentarlos y corregirlos.

PREGUNTAS ORIENTADORAS DEL PROYECTO

El pipeline debe responder con evidencia a cada una de estas preguntas:

1. ¿Cuál es el estado inicial del dataset? (dimensiones, tipos, faltantes, duplicados)
2. ¿Qué problemas de calidad existen, dónde están y cuál es su magnitud?
3. ¿Qué criterio se usó para tratar cada tipo de problema? ¿Por qué ese criterio y no otro?
4. ¿Cómo se estandarizaron las escalas de respuesta?
5. ¿Cuántos registros y variables se perdieron o transformaron durante la limpieza?
6. ¿Cómo se verificó que el dataset limpio es correcto?
7. ¿Qué diferencias estadísticas existen entre el dataset sucio y el dataset limpio?
8. ¿El dataset limpio está listo para análisis? ¿Qué garantías pueden dar al equipo de análisis?

Entregables técnicos:

Entregable 1 — Auditoría inicial del dataset (Data Profiling)

El primer paso antes de tocar un solo dato es entender qué tiene el dataset. Este entregable debe incluir:

- Reporte de dimensiones: filas, columnas, tipos de dato
- Conteo de valores faltantes por columna (absoluto y porcentual)
- Mapa de calor de valores faltantes (missingno o seaborn)
- Conteo de duplicados exactos.
- Distribución de valores únicos por variable categórica
- Estadísticos básicos de variables numéricas (para detectar outliers por rango)
- Reporte de tipos de dato inconsistentes por columna
- Documento de hallazgos: tabla con cada problema encontrado, la columna afectada, la magnitud y el tipo de problema.

Entregable 2 — Tratamiento de duplicados

- Identificación de filas duplicadas por subconjunto de columnas (no solo por ID, que puede diferir).
- Criterio documentado: ¿cuál duplicado se conserva?, ¿cuál se elimina? (primero, último, o por otra lógica).
- Verificación antes y después: conteo de registros.
- **Advertencia:** eliminar duplicados sin criterio claro puede generar sesgos → **justificar**.

Entregable 3 — Estandarización de variables categóricas

- Limpieza de espacios extra de texto antes de cualquier otra operación
- Normalización de mayúsculas/minúsculas
- Corrección de typos por mapeo explícito (diccionario de correcciones documentado)
- Verificación de categorías resultantes por variable
- Tabla de antes/después para cada variable corregida

Entregable 4 — Tratamiento de escalas Likert

- Construcción del diccionario de mapeo para cada escala:
 - Escala frecuencia 1-5: Nunca(1) → Siempre(5)
 - Escala acuerdo 1-7: Muy en desacuerdo(1) → Muy de acuerdo(7)
 - Escala somatización: Nunca(1) → Siempre(7)
- Unificación de variantes textuales al valor canónico antes de mapear a número
- Conversión de columnas BP (Bienestar Percibido): tratar los valores texto ("uno", "dos"...) → número.
- Aplicación del mapeo numérico a todos los ítems de escala
- Verificación de rangos post-codificación: ningún valor fuera del rango permitido por escala.
- Tratamiento del ítem inverso IR1: documentar y aplicar inversión (8 - IR1).

Entregable 5 — Tratamiento de valores faltantes

Este entregable tiene mayor complejidad deliberada. El equipo debe:

- **Fase A** — Identificar tipos de faltantes: ¿Los faltantes son MCAR (completamente aleatorios), MAR (aleatorios condicionados) o MNAR (no aleatorios)? Usar el test de Little o análisis visual de patrones.
- **Fase B** — Elegir estrategia por tipo de variable:
 - **Variables categóricas:** imputar con moda o categoría "No responde" (justificar)
 - **Variables de escala:** imputar con mediana por dimensión, o usar KNN imputer... (justificar).
 - **Variables numéricas:** imputar con mediana robusta.... (resistente a outliers).
- **Fase C — Verificación:**
 - Comparar distribución antes y después de imputación
 - Reportar cuántos valores fueron imputados por columna
 - Verificar que ninguna columna tenga faltantes residuales

Entregable 6 — Detección y tratamiento de outliers

- Detección con múltiples métodos.
 - Para cada outlier detectado: documentar valor original, variable afectada, fila, método de detección.
- Criterio de tratamiento (elegir y justificar uno):
 - Eliminación del registro
 - Imputación con mediana
 - Winsorización (reemplazar por el límite del rango válido)
 - Mantenimiento con flag ("outlier_flag" = 1)

- Visualización: boxplots antes y después del tratamiento

Entregable 7 — Construcción de variables derivadas

Una vez limpio el dataset a nivel de ítems, construir las 16 variables promedio por dimensión:

Dimensión	Variable
CTRL	CT1, CT2, CT3
PRES	PT1, PT2, PT3, PT4
LIDER	CL1, CL2, CL3, CL4, CL5, CL6, CL7
COMP	AC1, AC2, AC3
ROL_C	CR1, CR2, CR3, CR4
ROL_CON	CoR1, CoR2, CoR3
CAMBIO	GC1, GC2, GC3, GC4
SM_ORG	SM1, SM2, SM3, SM4, SM5
SAT	SAT1,...,SAT9
RETIRO	IR1, IR2, IR3, IR4
FAM_TRAB	FT1, FT2, FT3, FT4, FT5
TRAB_FAM	TF1, TF2, TF3, TF4, TF5
BURNOUT	BU1,...,BU12
BIENESTAR	BP1,...,BP10
SOMATIZ	SOM1,...,SOM5
DESGASTE	DL1,...,DL8

- **Verificar:**
 - Ningún promedio fuera del rango teórico de su escala.
 - Documentar cuántos registros tienen al menos un ítem
 - Faltante en una dimensión (imputado vs excluido)

Entregable 8 — Reporte de calidad final y comparativo

- **Tabla comparative antes y después del pipeline**

Métrica	Antes	Después
N registros	412	?
N duplicados	?	0
Variables con faltantes	?	0
.	?	0
.	?	0
.	?	0
Outliers detectados	?	0 (tratados)

- **Verificación de correlaciones clave:**
 - el dataset limpio debe mostrar las mismas relaciones que el estudio original ejemplo: (DESGASTE-SOMATIZ > .55, LIDER-SAT > .40, SAT-RETIRO < -.40)

Entregable 9 — Dashboard de calidad de datos en Streamlit (con este van a presentar!!!)

- **Panel 1 — Estado inicial**
 - Mapa de calor de faltantes
 - Conteo de problemas por tipo
 - Distribución de variables clave con los problemas visibles
- **Panel 2 — Explorador de problemas**
 - Selector de tipo de problema
 - Tabla de registros afectados
 - Visualización del problema específico
- **Panel 3 — Comparativo antes/después**
 - Selector de variable
 - Distribución antes (original) vs después (preprocesado)
 - Tabla de estadísticos comparativos
- **Panel 4 — Certificación de Calidad**
 - Semáforo de calidad por dimension
 - Verificación de correlaciones esperadas
 - Resumen ejecutivo del pipeline

Entregable para subir: Notebook de Python con la siguiente estructura:

Proyecto_final_preprocesamiento - GX.ipynb (X número del grupo asignado en la clase)

Sección 0 — Configuración

- Importación de librerías
- Carga del dataset original
- Función de reporte automático de calidad (se llamará al inicio y al final para comparar)

Sección 1 — Auditoría inicial (Data Profiling)

- Dimensiones y tipos de dato
- Análisis de valores faltantes
- Análisis de duplicados
- Análisis de variables categóricas
- Análisis de variables numéricas
- Tabla consolidada de problemas encontrados

Sección 2 — Tratamiento de duplicados

- Identificación por criterio lógico
- Eliminación con verificación

Sección 3 — Estandarización de texto

- Strip de espacios
- Normalización de mayúsculas
- Corrección de typos (diccionario)
- Verificación de categorías resultantes

Sección 4 — Codificación de escalas Likert

- Unificación de variantes textuales
- Definición de diccionarios de mapeo
- Conversión a numérico
- Corrección de BP (texto → número)
- Inversión de IR1
- Verificación de rangos

Sección 5 — Tratamiento de valores faltantes

- Análisis del patrón de faltantes
- Estrategia por tipo de variable
- Imputación
- Verificación de completitud

Sección 6 — Tratamiento de outliers

- Detección
- Documentación de casos
- Tratamiento
- Verificación

Sección 7 — Construcción de variables derivadas

- Cálculo de promedios por dimensión
- Verificación de rangos y coherencia

Sección 8 — Reporte comparativo final

- Tabla antes/después
- Verificación de correlaciones esperadas
- Exportación del dataset limpio
- Conclusiones del pipeline

Nota importante:

Este dataset fue generado con técnicas de síntesis estadística a partir de un estudio real sobre salud mental laboral en Colombia. Los patrones, distribuciones y correlaciones que encontrarán son estadísticamente reales y teóricamente fundamentados.

NO es un dataset de práctica inventado: los hallazgos que obtengan tienen interpretación psicológica y organizacional concreta. Se espera que el equipo investigue el significado de cada dimensión antes de interpretar los resultados.

Fuente del marco teórico: Demerouti, E., Bakker, A. B., Nachreiner, F., & Schaufeli, W. B. (2001). The job demands-resources model of burnout. *Journal of Applied Psychology*, 86(3), 499–512.

- **Fecha de cargue del notebook de Python + el vínculo del dashboard de streamlit (No debe correr local tiene que estar desplegado). Lunes 25 de mayo 23:59 horas**
- **Presentación del dashboard. Miércoles 27 de mayo. Desde las 11 horas.**